

Analiza danych klientów Telco Customer Churn

Katarzyna Bednarkiewicz, Ewelina Dąbrowa

2026-04-03

Spis treści

1	Przygotowanie danych. Podstawowe informacje o danych.	2
2	Analiza opisowa - wskaźniki sumaryczne i wykresy	6
3	Analiza opisowa z podziałem na grupy	13
4	Podsumowanie - wnioski z przeprowadzonej analizy	20

1 Przygotowanie danych. Podstawowe informacje o danych.

Wczytujemy dane z pliku *WA_Fn-UseC_-Telco-Customer-Churn.csv*.

Typy poszczególnych zmiennych można sprawdzić za pomocą funkcji `str()`.

Rozmiar danych (liczba przypadków i cech)

Liczba cech wynosi 21 a liczba rekordów wynosi 7043.

Poszczególne cechy to

- **gender** (factor; 2 poziomy: Female/Male) - płeć klienta
- **SeniorCitizen** (numeric; zakres: 0-1) - informacja czy klient jest emerytem
- **Partner** (factor; 2 poziomy: No/Yes) - informacja czy klient posiada partnera
- **Dependents** (factor; 2 poziomy: No/Yes) - informacja czy klient posiada kogoś na utrzymaniu
- **tenure** (numeric; zakres: 0-72) - liczba miesięcy przez ile klient pozostał w firmie
- **PhoneService** (factor; 2 poziomy: No/Yes) - informacja czy klient posiada usługę telefoniczną
- **MultipleLines** (factor; 3 poziomy: No/No phone service/Yes) - informacja czy klient posiada wiele linii
- **InternetService** (factor; 3 poziomy: DSL/Fiber optic/ No) - dostawca usług internetowych klienta
- **OnlineSecurity** (factor; 3 poziomy: No/No internet service/Yes) - informacja czy klient posiada ochronę w internecie
- **OnlineBackup** (factor; 3 poziomy: No/No internet service/Yes) - informacja czy klient posiada zapasową kopię online
- **DeviceProtection** (factor; 3 poziomy: No/No internet service/Yes) - informacja czy klient posiada ochronę urządzenia
- **TechSupport** (factor; 3 poziomy: No/No internet service/Yes) - informacja czy klient posiada serwis techniczny
- **StreamingTV** (factor; 3 poziomy: No/No internet service/Yes) - informacja czy klient posiada telewizję strumieniową
- **StreamingMovies** (factor; 3 poziomy: No/No internet service/Yes) - informacja czy klient posiada strumieniowe przesyłanie filmów

- **Contract** (factor; 3 poziomy: Month-to-month/One year/Two year) - okres obowiązywania umowy z klientem
- **PaperlessBilling** (factor; 2 poziomy: No/Yes) - informacja czy klient posiada fakturowanie bez papieru
- **PaymentMethod** (factor; 4 poziomy: Electronic check/Mailed check/Bank transfer(automatic)/Credit card(automatic)) - metoda płatności klienta
- **MonthlyCharges** (numeric; zakres: 18.25-118.75) - kwota pobierana od klienta miesięcznie
- **TotalCharges** (numeric; zakres: 18.80-8684.80) - całkowita kwota pobrana od klienta
- **Churn** (factor; 2 poziomy: No/Yes) - informacja czy klient odszedł z firmy

Typy poszczególnych cech

Zmienne ilościowe to:

- **SeniorCitizen, tenure, MonthlyCharges, TotalCharges.**

Zmienne jakościowe to:

- **customerID, gender, Partner, Dependents, PhoneService, MultipleLines, InternetService, OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies, Contract, PaperlessBilling, PaymentMethod, Churn.**

Liczba poziomów dla cechy **customerID** wynosi 7043, zatem zmienna ta pełni rolę identyfikatora klientów, więc ją usuwamy.

Informacja na temat braków danych (numery wierszy i nazwy cech) jest podana w Tabeli 1. Łącznie zaobserwowaliśmy 11 brakujących danych, które kodowane są za pomocą symbolu NA. Ilość braków w porównaniu z ilością obserwacji jest niska, dlatego usunięcie ich nie spowoduje utraty kluczowych dla analizy informacji. Ponadto usunięte dane dotyczyły nowych klientów, którzy dopiero rozpoczęli staż w firmie i nie posiadali jeszcze żadnych kosztów całkowitych, więc usunięcie ich pozwoliło urzetelnić statystyki dla zmiennych **TotalCharges** oraz **tenure**.

Wiersz	Cecha
489	TotalCharges
754	TotalCharges
937	TotalCharges
1083	TotalCharges
1341	TotalCharges
3332	TotalCharges
3827	TotalCharges
4381	TotalCharges
5219	TotalCharges
6671	TotalCharges
6755	TotalCharges

Tabela 1: Braki w danych.

Zmienną **SeniorCitizen** w celu dalszej analizy zmieniamy na typ factor z dwoma poziomami, które informują, czy klient jest emerytem: “No” - nie, “Yes” - tak.

Zmienna	Wartości	Poziomy
gender	Female; Male	Female; Male
SeniorCitizen	No; Yes	No; Yes
Partner	No; Yes	No; Yes
Dependents	No; Yes	No; Yes
PhoneService	No; Yes	No; Yes
MultipleLines	No; No phone service; Yes	No; No phone service; Yes
InternetService	DSL; Fiber optic; No	DSL; Fiber optic; No
OnlineSecurity	No; No internet service; Yes	No; No internet service; Yes
OnlineBackup	No; No internet service; Yes	No; No internet service; Yes
DeviceProtection	No; No internet service; Yes	No; No internet service; Yes
TechSupport	No; No internet service; Yes	No; No internet service; Yes
StreamingTV	No; No internet service; Yes	No; No internet service; Yes
StreamingMovies	No; No internet service; Yes	No; No internet service; Yes
Contract	Month-to-month; One year; Two year	Month-to-month; One year; Two year
PaperlessBilling	No; Yes	No; Yes
PaymentMethod	Bank transfer (automatic); Credit card (automatic); Electronic check; Mailed check	Bank transfer (automatic); Credit card (automatic); Electronic check; Mailed check
Churn	No; Yes	No; Yes

Tabela 2: Porównanie wartości unikalnych z poziomami dla zmiennych jakościowych

	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
tenure	1.00	9.00	29.00	32.42	55.00	72.00
MonthlyCharges	18.25	35.59	70.35	64.80	89.86	118.75
TotalCharges	18.80	401.45	1397.47	2283.30	3794.74	8684.80

Tabela 3: Wskaźniki sumaryczne dla zmiennych ilościowych

Wniosek: Dla każdej zmiennej jakościowej lista wartości przyjmowana przez daną cechę pokrywa się z liczbą jej poziomów, zatem nie występują żadne niestandardowe kodowania wartości brakujących. Dla zmiennych ilościowych ich wskaźniki sumaryczne również nie wskazują na występowanie jakichś niestandardowych kodowań.

2 Analiza opisowa - wskaźniki sumaryczne i wykresy

Podstawowe wskaźniki sumaryczne (miary położenia i rozproszenia) dla poszczególnych cech/zmiennych.

Wartości miar położenia, rozproszenia oraz koncentracji i asymetrii dla zmiennej **MonthlyCharges** można znaleźć w Tabelach 4, 5 oraz 6.

	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
MonthlyCharges	18.25	35.59	70.35	64.80	89.86	118.75

Tabela 4: Miary położenia dla zmiennej MonthlyCharges

	odchylenie standardowe	rozstęp międzykwartylowy	rozstęp
MonthlyCharges	30.09	54.27	100.50

Tabela 5: Miary rozproszenia dla zmiennej MonthlyCharges

	skośność	kurtoza
MonthlyCharges	-0.22	-1.26

Tabela 6: Miary koncentracji i asymetrii dla zmiennej MonthlyCharges

Na podstawie wyników z Tabel 4, 5, 6 średnia miesięcznych opłat wynosi 64.8, natomiast mediana jest od niej wyższa i wynosi 70.35, co sugeruje występowanie asymetrii lewostronnej. Potwierdza to współczynnik skośności równy -0.22. Oznacza to, że większość klientów wnosi wyższe opłaty niż wynosi wartość średnia. Opłaty są bardzo zróżnicowane, świadczy o tym odchylenie standardowe wynoszące aż 30.09 oraz szeroki rozstęp równy 100.5. Połowa klientów płaci kwoty w przedziale od 35.59 do 89.86, czyli rozstęp międzykwartylowy jest szeroki i wynosi 54.27. Ujemna kurtoza równa -1.26 sugeruje, że rozkład jest płaski.

Wartości miar położenia, rozproszenia oraz koncentracji i asymetrii dla zmiennej **tenure** można znaleźć w Tabelach 7, 8 oraz 9.

	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
tenure	1.00	9.00	29.00	32.42	55.00	72.00

Tabela 7: Miary położenia dla zmiennej tenure

	odchylenie standardowe	rozstęp międzykwartylowy	rozstęp
tenure	24.55	46.00	71.00

Tabela 8: Miary rozproszenia dla zmiennej tenure

	skośność	kurtoza
tenure	0.24	-1.39

Tabela 9: Miary koncentracji i asymetrii dla zmiennej tenure

Na podstawie wyników z Tabel 7, 8, 9 średni staż klientów wynosi 32.42, natomiast mediana jest od niej niższa i wynosi 29, co sugeruje występowanie asymetrii prawostronnej. Potwierdza to dodatni współczynnik skośności równy 0.24. Oznacza to, że większość klientów ma staż krótszy niż średni, a średnią zawyża grupa długoletnich, lojalnych użytkowników. Staż klientów jest bardzo zróżnicowany, o czym świadczy odchylenie standardowe wynoszące 24.55 oraz szeroki rozstęp całkowity równy 71. Połowa osób posiada staż w przedziale od 9 do 55 miesięcy (rozstęp międzykwartylowy wynosi 46). Bardzo niska, ujemna wartość kurtozy wynosząca -1.39 wskazuje na wyraźne spłaszczenie rozkładu.

Wartości miar położenia, rozproszenia oraz koncentracji i asymetrii dla zmiennej **TotalCharges** można znaleźć w Tabelach 10, 11 oraz 12.

	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
TotalCharges	18.80	401.45	1397.47	2283.30	3794.74	8684.80

Tabela 10: Miary położenia dla zmiennej TotalCharges

	odchylenie standardowe	rozstęp międzykwartylowy	rozstęp
TotalCharges	2266.77	3393.29	8666.00


Tabela 11: Miary rozproszenia dla zmiennej TotalCharges

	skośność	kurtoza
TotalCharges	0.96	-0.23

Tabela 12: Miary koncentracji i asymetrii dla zmiennej TotalCharges

Na podstawie wyników z Tabel 10, 11, 12 średnia suma opłat wynosi 2283.3, natomiast mediana jest od niej znacznie niższa i wynosi 1397.47, co sugeruje występowanie asymetrii prawostronnej. Potwierdza to wysoki współczynnik skośności równy aż 0.96. Oznacza to, że średnią zawyża grupa klientów o bardzo wysokich opłatach. Zmienna jest bardzo zróżnicowana, o czym świadczy szeroki rozstęp wynoszący 8666 oraz odchylenie standardowe zbliżone do średniej (2266.77). Połowa klientów mieści się w przedziale od 401.45 do 3794.74 (rozstęp międzykwartylowy wynosi 3393.29). Wartość kurtozy wynosi -0.23 i jest bliska zeru.


Zaczynamy od wykresów dla zmiennych ilościowych.



Rysunek 1: Histogramy i wykresy pudełkowe dla zmiennych tenure, MonthlyCharges, TotalCharges

Wykresy przedstawione na Rysunku 1 wskazują na znaczne zróżnicowanie klientów. Najliczniejszą grupę stanowią klienci o najkrótszym stażu (0-5 miesięcy), co widać na histogramie dla zmiennej **tenure**. Długi prawy ogon rozkładu potwierdza asymetrię prawostronną. Analogiczne zjawisko, lecz o jeszcze większym nasileniu, obserwujemy dla zmiennej **TotalCharges**. Zdecydowana większość wartości koncentruje się przy niskich opłatach całkowitych. W przypadku **MonthlyCharges** przesunięcie wykresu pudełkowego w kierunku wyższych wartości, mediana znajdująca się powyżej środka oraz kształt histogramu potwierdzają występowanie asymetrii lewostronnej, jednak widać bardzo wysoki słupek przy niskich opłatach miesięcznych. Sugeruje to istnienie grupy klientów, która nie korzysta z żadnych drogiej dodatkowych usług. Warto zwrócić uwagę, że na wykresach pudełkowych dla wszystkich trzech zmiennych nie występują wartości odstające. Oznacza to, że mimo szerokiego rozstępu danych, nie obserwujemy żadnych anomalii.

A teraz wykresy oraz tabele licznosci dla zmiennych jakościowych.



Rysunek 2: Wykresy słupkowe dla zmiennych InternetService, OnlineSecurity, OnlineBackup, TechSupport, Contract, PaymentMethod

Tabele licznosci dla zmiennych jakościowych znajdują się w Tabelach 13, 14, 15, 16, 17 oraz 18.

InternetService	
DSL	2416
Fiber optic	3096
No	1520

Tabela 13: Tabela licznosci dla cechy InternetService

OnlineSecurity	
No	3497
No internet service	1520
Yes	2015

Tabela 14: Tabela licznosci dla cechy OnlineSecurity

OnlineBackup	
No	3087
No internet service	1520
Yes	2425

Tabela 15: Tabela licznosci dla cechy OnlineBackup

	TechSupport
No	3472
No internet service	1520
Yes	2040

Tabela 16: Tabela liczności dla cechy TechSupport

	Contract
Month-to-month	3875
One year	1472
Two year	1685

Tabela 17: Tabela liczności dla cechy Contract

	PaymentMethod
Bank transfer (automatic)	1542
Credit card (automatic)	1521
Electronic check	2365
Mailed check	1604

Tabela 18: Tabela liczności dla cechy PaymentMethod


Na podstawie wykresów słupkowych przedstawionych na Rysunku 2 oraz Tabel liczności (13, 14, 15, 16, 17 oraz 18) możemy zauważyć, że najliczniejsza grupa klientów korzysta z internetu światłowodowego (3096 osób) i jest to najpopularniejsza usługa oferowana przez firmę. Jedynie około 1520, co stanowi 21.62% klientów, w ogóle nie posiada usługi internetowej. W przypadku zmiennych takich jak **OnlineSecurity**, **OnlineBackup** czy **TechSupport**, dominuje wartość “No”, co oznacza, że klienci rzadko decydują się na korzystanie z usług dodatkowych. Największa grupa klientów wybiera umowy krótkoterminowe typu **Month-to-month** (3875 osób), a kontrakty długoterminowe (roczne i dwuletnie) stanowią mniejszość (łącznie 3157). Najpopularniejszą metodą płatności jest **Electronic check** (2365 osób), natomiast pozostałe metody (**Bank transfer**, **Credit card** oraz **Mailed check**) są wybierane rzadziej (1542, 1521 oraz 1604).

Wykorzystując wykresy rozrzutu dla par zmiennych ciągłych, sprawdzimy czy występują istotne (np. liniowe) zależności pomiędzy zmiennymi.

	tenure	MonthlyCharges	TotalCharges
tenure	1.00	0.25	0.83
MonthlyCharges	0.25	1.00	0.65
TotalCharges	0.83	0.65	1.00

Tabela 19: Współczynniki korelacji zmiennych ilościowych

Wykresy rozrzutu dla zmiennych ilościowych



Rysunek 3: Wykresy rozrzutu dla zmiennych ilościowych

Na podstawie danych z Tabeli 19 współczynnik korelacji pomiędzy zmienną **tenure** a **TotalCharges** wynosi aż 0.83, co oznacza silną zależność liniową. Wraz ze stażem klienta rośnie łączna suma dokonanych przez niego wpłat. Istotną zależność widzimy również pomiędzy **MonthlyCharges** a **TotalCharges** (współczynnik korelacji równy 0.65). Zjawisko to wydaje się być oczekiwane, im wyższe opłaty miesięczne, tym większa suma łącznie wszystkich wpłat. Między **tenure** a **MonthlyCharges** korelacja jest niska i wynosi 0.25, co wskazuje na brak wyraźnej liniowej zależności między stażem klienta a jego miesięcznymi opłatami. Opisane zależności można zaobserwować na rysunku 3.

- Zmienna **MonthlyCharges** przyjmuje wartości w zakresie od 18.25 do 118.75 USD. Szeroki rozstęp równy 100.50 USD świadczy o dużym zróżnicowaniu cenowym oferty firmy.
- Zmienna **tenure** przyjmuje wartości w zakresie od 1 do 72 miesięcy. Staż klientów jest zróżnicowany, mamy klientów nowych oraz bardzo lojalnych, których staż sięga aż 72 miesięcy.
- Zmienna **TotalCharges** przyjmuje wartości w zakresie od 18.80 do 8684.80 USD. Duży rozstęp równy 8666.00 USD wynika z różnic w stażu klientów oraz zależności pomiędzy stażem a łącznymi wniesionymi opłatami.

i. Czy wszystkie zmienne mają rozkład symetryczny?

Żadna ze zmiennych nie ma rozkładu symetrycznego. Zmienne **tenure** oraz **TotalCharges** charakteryzują się asymetrią prawostronną, zaś **MonthlyCharges** lewostronną.

ii. Które cechy charakteryzują się największą zmiennością?

Podstawowe wskaźniki sumaryczne oraz wartości współczynnika zmienności dla danych zmiennych przedstawiono w Tabeli 20.

	Średnia	Odchylenie standardowe	Wariancja	Współczynnik zmienności
tenure	32.42	24.55	602.47	75.71
MonthlyCharges	64.80	30.09	905.17	46.43
TotalCharges	2283.30	2266.77	5138252.41	99.28

Tabela 20: Miary zmienności zmiennych ilościowych

Na podstawie wyników z Tabeli 20 widzimy, że największą zmiennością charakteryzuje się cecha **TotalCharges**, której współczynnik zmienności wynosi aż 99.28%. Wysoka zmienność występuje także dla cechy **tenure** i jest ona równa 75.71%, a najmniejsza, lecz również istotna, dla **MonthlyCharges** wynosząca 46.43%.

Zdecydowana większość klientów korzysta z usługi **PhoneService**. Zmienna **InternetService** najczęściej przyjmuje kategorię **Fiber optic**, następnie **DSL**, a najmniejsza liczba

klientów wcale nie korzysta z usług internetowych. Większość klientów nie korzysta z usług dodatkowych, takich jak **OnlineSecurity** i **TechSupport**. Najczęściej wybieranym typem umowy jest **Month-to-month**, a umowy długoterminowe (roczne i dwuletnie) są znacznie mniej popularne. Najpopularniejszą metodą płatności jest **Electronic check**, natomiast pozostałe metody są wybierane rzadziej.

3 Analiza opisowa z podziałem na grupy

Przeprowadzamy analizę opisową, tym razem jednak z podziałem na dwie grupy: grupa 1: Churn=='Yes' – grupa klientów, którzy odeszli (zrezygnowali), grupa 2: Churn=='No' – grupa lojalnych klientów (korzystają dalej z usług firmy).

Wyznamy na początku podstawowe wskaźniki sumaryczne dla poszczególnych zmiennych numerycznych.

Wartości miar położenia, rozproszenia oraz koncentracji i asymetrii dla zmiennej **MonthlyCharges** z podziałem na lojalnych i tych, którzy zakończyli współpracę, można znaleźć w Tabelach 21, 22 oraz 23.

	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
MonthlyCharges - lojalni	18.25	25.10	64.45	61.31	88.47	118.75
MonthlyCharges - odeszli	18.85	56.15	79.65	74.44	94.20	118.35

Tabela 21: Miary położenia dla zmiennej MonthlyCharges z podziałem na klientów którzy pozostali i odeszli.

	odchylenie standardowe	rozstęp międzykwartyłowy	rozstęp
MonthlyCharges - lojalni	31.09	63.37	100.50
MonthlyCharges - odeszli	24.67	38.05	99.50

Tabela 22: Miary rozproszenia dla zmiennej MonthlyCharges z podziałem na klientów którzy pozostali i odeszli.

	skośność	kurtoza
MonthlyCharges - lojalni	-0.03	-1.36
MonthlyCharges - odeszli	-0.73	-0.37

Tabela 23: Miary koncentracji i asymetrii dla zmiennej MonthlyCharges z podziałem na klientów którzy pozostali i odeszli.

Średnie miesięczne koszty dla lojalnych klientów wynoszą 61.31, natomiast dla tych co odeszli wynoszą 74.44. Mediana jest w obu przypadkach wyższa od średniej i wynosi kolejno 64.45

oraz 79.65, co sugeruje asymetrię lewostronną. Współczynnik skośności dla stałych klientów, wynoszący -0.03, jest bliski zeru, a więc można powiedzieć, że mamy w tym przypadku do czynienia z rozkładem niemal symetrycznym. W przypadku klientów, którzy odeszli, współczynnik skośności jest już wyraźniejszy i wynosi -0.73, co sugeruje, że mamy do czynienia z rozkładem umiarkowanie skośnym. Rozstęp jest szeroki i wynosi 100.5 w przypadku klientów lojalnych i 99.5 w przypadku tych, którzy zrezygnowali z usług. Jednak duża różnica występuje dla rozstępu międzykwartylowego (63.37 i 38.05), który świadczy o tym, że w grupie klientów nielojalnych opłaty są bardziej zbliżone do siebie (oscylują wokół wyższych wartości, na co wskazuje średnia i mediana w ich grupie). Tak samo odchylenie standardowe jest stosunkowo duże (31.09 oraz 24.67), co w połączeniu z rozstępem oznacza duże zróżnicowanie miesięcznych opłat zarówno dla lojalnych jak i nielojalnych, jednak w przypadku nielojalnych, to zróżnicowanie jest znacznie mniejsze (co potwierdza kurtoza).

Wartości miar położenia, rozproszenia oraz koncentracji i asymetrii dla zmiennej **tenure** z podziałem na lojalnych i tych, którzy zakończyli współpracę, można znaleźć w Tabelach 24, 25 oraz 26.

	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
tenure - lojalni	1.00	15.00	38.00	37.65	61.00	72.00
tenure - odeszli	1.00	2.00	10.00	17.98	29.00	72.00

Tabela 24: Miary położenia dla zmiennej tenure z podziałem na klientów którzy pozostali i odeszli.

	odchylenie standardowe	rozstęp międzykwartylowy	rozstęp
tenure - lojalni	24.08	46.00	71.00
tenure - odeszli	19.53	27.00	71.00

Tabela 25: Miary rozproszenia dla zmiennej tenure z podziałem na klientów którzy pozostali i odeszli.

	skośność	kurtoza
tenure - lojalni	-0.03	-1.41
tenure - odeszli	1.15	0.19

Tabela 26: Miary koncentracji i asymetrii dla zmiennej tenure z podziałem na klientów którzy pozostali i odeszli.

Średnia ilość miesięcy dla lojalnych klientów wynosi 37.65, natomiast dla tych co odeszli wynosi 17.98. Mediana wynosi kolejno 38 oraz 10, co sugeruje rozkład niemal symetryczny dla lojalnych i asymetrię prawostronną dla nielojalnych. Współczynnik skośności dla stałych klientów, wynoszący -0.03, jest bliski zeru, a więc możemy potwierdzić nasze wcześniejsze przypuszczenia na temat typu rozkładu dla tej grupy. W przypadku klientów, którzy odeszli, współczynnik skośności jest znacznie wyraźniejszy i wynosi 1.15, co sugeruje, że mamy do

czynienia z rozkładem silnie skośnym. Rozstęp jest szeroki i wynosi 71 w obu przypadkach. Jednak spora różnica występuje dla rozstępu międzykwartylowego (46 i 27), który świadczy o tym, że w grupie klientów nielojalnych ilość miesięcy przez które klient pozostał w firmie jest bardziej zbliżona do siebie (oscyluje wokół niższych wartości, na co również wskazuje średnia i mediana). Tak samo odchylenie standardowe jest stosunkowo duże (24.08 oraz 19.53), co w połączeniu z rozstępem oznacza duże zróżnicowanie ilości miesięcy spędzonych w firmie zarówno dla lojalnych jak i nielojalnych, jednak w przypadku nielojalnych, to zróżnicowanie jest znacznie mniejsze, a ich wartości stażu są znacznie silniej skoncentrowane, o czym świadczy kurtoza wynosząca 0.19. Dla lojalnych kurtoza równa -1.41 mówi o tym, że ich rozkład jest spłaszczony (klienci nie skupiają się wokół jednej, konkretnej długości stażu).

Wartości miar położenia, rozproszenia oraz koncentracji i asymetrii dla zmiennej **TotalCharges** z podziałem na lojalnych i tych, którzy zakończyli współpracę, można znaleźć w Tabelach 27, 28 oraz 29.

	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
TotalCharges - lojalni	18.80	577.83	1683.60	2555.34	4264.12	8672.45
TotalCharges - odeszli	18.85	134.50	703.55	1531.80	2331.30	8684.80

Tabela 27: Miary położenia dla zmiennej TotalCharges z podziałem na klientów którzy pozostali i odeszli.

	odchylenie standardowe	rozstęp międzykwartylowy	rozstęp
TotalCharges - lojalni	2329.46	3686.30	8653.65
TotalCharges - odeszli	1890.82	2196.80	8665.95

Tabela 28: Miary rozproszenia dla zmiennej TotalCharges z podziałem na klientów którzy pozostali i odeszli.


	skośność	kurtoza
TotalCharges - lojalni	0.81	-0.55
TotalCharges - odeszli	1.51	1.45

Tabela 29: Miary koncentracji i asymetrii dla zmiennej TotalCharges z podziałem na klientów którzy pozostali i odeszli.

Średnie całkowite koszty dla lojalnych klientów wynoszą 2555.34, natomiast dla tych co odeszli wynoszą średnio 1531.8. Mediana jest w obu przypadkach niższa od średniej i wynosi kolejno 1683.6 oraz 703.55, co sugeruje znaczną asymetrię prawostronną. Współczynnik skośności dla stałych klientów wynosi 0.81, więc mamy do czynienia z rozkładem umiarkowanie skośnym. W przypadku klientów, którzy odeszli, współczynnik skośności jest bardziej wyraźny i wynosi 1.51, co sugeruje, że mamy do czynienia z rozkładem silnie skośnym. Rozstęp jest szeroki i podobny dla obu grup (wynoszący około 8660). Jednak dosyć duża różnica

występuje dla rozstępu międzykwartylowego (3686.3 i 2196.8), który świadczy o tym, że w grupie klientów nielojalnych całkowite opłaty są bardziej zbliżone do siebie (oscylują wokół niższych wartości, co potwierdza średnia i mediana w ich grupie oraz dodatnia kurtoza). Tak samo odchylenie standardowe jest stosunkowo duże (2329.46 oraz 1890.82), co w połączeniu z rozstępem oznacza duże zróżnicowanie opłat zarówno dla lojalnych jak i nielojalnych, jednak w przypadku nielojalnych, to zróżnicowanie jest znacznie mniejsze.


Zajmijmy się teraz zilustrowaniem rozkładów poszczególnych cech za pomocą odpowiednich wykresów. Zaczniemy od wykresów dla zmiennych ilościowych.



Rysunek 4: Histogramy, wykresy pudełkowe oraz estymatory jądrowe gęstości dla zmiennych tenure, MonthlyCharges, TotalCharges z podziałem na klientów lojalnych i tych którzy odeszli.

Wykresy dla zmiennych ilościowych przedstawione na Rysunku 4 potwierdzają nasze wcześniejsze przypuszczenia nt. rozkładów poszczególnych grup. Dla zmiennej **tenure** wykres gęstości oraz histogram dla klientów lojalnych, wykazują rozkład niemal symetryczny z lekkimi pikami na końcach. Potwierdzają one otrzymaną w Tabeli 26 ujemną kurtozę (-1.41) – dane nie koncentrują się wokół średniej. Histogram jak i wykres gęstości empirycznej dla klientów, którzy odeszli wyraźnie opada w prawo, co potwierdza silną asymetrię prawostronną (skośność 1.15), zatem możemy wywnioskować, że większość osób rezygnuje na bardzo wczesnym etapie. Wykres pudełkowy uwydatnia znaczącą różnicę w medianach. Klienci lojalni mają znacznie wyższy “środek ciężkości” stażu niż ci, którzy odeszli. Przyjrzyjmy się teraz zmiennej **MonthlyCharges**. Wykresy gęstości i histogramy ujawniają cechę, której nie widać w tabelach – rozkład jest bimodalny. Mamy dużą grupę klientów z niskimi opłatami (ok. 20-25 USD) oraz drugą grupę z wysokimi (ok. 70-100 USD). U klientów, którzy odeszli, wykres gęstości jest wyraźniej przesunięty w stronę wyższych wartości. Potwierdza to wyższą średnią (74.44) w porównaniu do lojalnych (61.31) (dane z Tabeli 21). Zajmijmy się teraz zmienną **TotalCharges**. Wszystkie wykresy dla tej zmiennej zarówno dla lojalnych, jak i tych, co odeszli, wykazują silną asymetrię prawostronną. Długie “ogony” ciągnące się w stronę wysokich wartości potwierdzają dodatnią skośność (0.81 i 1.51). Na wykresie pudełkowym dla grupy nielojalnych widać liczne punkty powyżej górnego wąsa. Są to klienci, którzy pomimo krótkiego stażu (co wiemy z analizy **tenure**) wygenerowali bardzo wysokie koszty całkowite przed odejściem. Wykres gęstości dla tej samej grupy jest znacznie “smuklejszy” i wyższy przy niskich wartościach, co koresponduje z dodatnią kurtozą (1.45) – oznacza to większą koncentrację wydatków w niższych przedziałach kwotowych w tej grupie.

Przejdźmy teraz do wykresów dla zmiennych jakościowych.



Rysunek 5: Wykresy słupkowe dla zmiennych Contract, InternetService, PaymentMethod, OnlineSecurity, TechSupport, OnlineBackup

Przeanalizujemy wykresy dla zmiennych jakościowych znajdujące się na Rysunku 5. Przyjrzyjmy się najpierw zmiennej **Contract**. Jest to definitywnie zmienna o najsilniejszym znaczeniu wizualnym. Wśród osób, które odeszły, dominują klienci z umową Month-to-month. Liczba rezygnacji przy umowach rocznych i dwuletnich jest marginalna. Sugeruje to, że brak długoterminowego zobowiązania jest głównym czynnikiem ułatwiającym decyzję o odejściu. Przejdźmy do zmiennej **InternetService**. Największy odsetek rezygnacji obserwujemy u użytkowników światłowodu. U klientów lojalnych rozkład między DSL a światłowodem jest bardziej wyrównany. Może to wskazywać na niezadowolenie z ceny lub jakości światłowodu w

tej grupie. Analizując zmienną **PaymentMethod**, zauważyć można, że klienci, którzy odeszli, najczęściej korzystali z czeków elektronicznych. Pozostałe metody nie były tak częstym powodem odejść jak właśnie чеки elektroniczne. U lojalnych klientów rozkład metod płatności jest niemal równomierny. Rozpatrzmy teraz zmienne **OnlineSecurity**, **TechSupport** oraz **OnlineBackup**. We wszystkich trzech przypadkach u klientów, którzy odeszli, dominuje kategoria “No” (brak usługi). Klienci posiadający wsparcie techniczne lub dodatkowe zabezpieczenia odchodzą znacznie rzadziej. Z tych danych możemy zatem wywnioskować, że posiadanie usług dodatkowych silnie koreluje z lojalnością klienta – prawdopodobnie budują one większą wartość relacyjną i utrudniają rezygnację.

Zmiennymi, które charakteryzują się największym zróżnicowaniem rozkładu w grupach, są:

- **tenure**, **MonthlyCharges**, **Contract**, **InternetService**, **PaymentMethod**, **OnlineSecurity**, **TechSupport**, **OnlineBackup**, **DeviceProtection**, **StreamingMovies**, **StreamingTV**.

4 Podsumowanie - wnioski z przeprowadzonej analizy

Na podstawie przeprowadzonych analiz możemy wyciągnąć kilka kluczowych wniosków. Większość klientów firmy korzysta z umów krótkoterminowych typu **Month-to-month**, co również potwierdza czas stażu klientów - większość z nich to osoby ze stażem w zakresie 0-5 miesięcy. Istnieje silna korelacja między długością stażu a całkowitymi wniesionymi opłatami, jednak nie zaobserwowano związku pomiędzy stażem (**tenure**) a wysokością miesięcznych opłat (**MonthlyCharges**). Najpopularniejszą usługą oferowaną przez firmę jest światłowód (**Fiber optic**), natomiast klienci rzadko decydują się na korzystanie z usług dodatkowych. Najczęściej wybieraną metodą płatności jest czek elektroniczny (**Electronic check**).

Większość klientów wybiera krótkie umowy miesięczne typu **Month-to-month**, jednak jest to typ umowy, który nie sprzyja lojalności klientów - odchodzą oni zdecydowanie częściej, niż ci korzystający z długoterminowych umów. Najczęściej wybieranymi usługami są usługi telefoniczne oraz internetowe (**Fiber optic**, **DSL**). Najpopularniejszą usługą oferowaną przez firmę jest internet światłowodowy **Fiber optic**, jednocześnie jest to jednak usługa, której użytkownicy najczęściej rezygnują z usług firmy. Usługi dodatkowe, takie jak ochrona online, wsparcie techniczne i backup (**OnlineSecurity**, **TechSupport**, **OnlineBackup**) są zdecydowanie mniej popularne. Klienci są bardzo zróżnicowani pod względem łącznych wniesionych opłat (**TotalCharges**), co wynika głównie ze znacznych różnic w stażu (**tenure**).

- Jaka jest główna przyczyna odchodzenia klientów?

Innymi słowy, czym charakteryzują się klienci rezygnujący z usług firmy?

- Co firma powinna zrobić, aby przeciwdziałać odchodzeniu klientów?

Około 26.58% ogółu badanych to osoby, które nie zdecydowały się przedłużyć umowy z firmą. W grupie tej dominują klienci korzystający z krótkoterminowych umów typu **Month-to-month**, podczas gdy posiadacze zobowiązań długoterminowych (rocznych i dwuletnich) odchodzą znacznie rzadziej. Ponadto, nie korzystają oni zazwyczaj z ochrony online, wsparcia technicznego czy też backupu (**OnlineSecurity**, **TechSupport**, **OnlineBackup**). Klienci, którzy odchodzą najczęściej, charakteryzują się także tym, że korzystają z płatności czekiem elektronicznym (**Electronic check**) oraz ze światłowodu (usługa **Fiber optic**).

Aby zwiększyć lojalność klientów, firma powinna zachęcać do wybierania umów długoterminowych, na przykład poprzez dodanie interesujących bonusów lojalnościowych. Ponadto, warto promować korzystanie z usług dodatkowych, takich jak ochrona online, wsparcie techniczne i backup. Firma powinna również przyjrzeć się jakości usług światłowodowych i metody płatności czekiem elektronicznym.